

Credit Risk Model Development and Monitoring

Разработка, калибровка и стресс-тестирование PD-модели

Задача:	прогноз вероятности дефолта клиента по кредитной карте
Модели:	Logistic Regression, Random Forest, HistGradientBoosting, LightGBM
Оценка:	ROC-AUC, Brier Score, business cost, bootstrap, SHAP и PSI

Краткое резюме

Главный результат

Нелинейные модели устойчиво превосходили логистическую регрессию по ROC-AUC. При этом Random Forest, HistGradientBoosting и LightGBM показали практически одинаковую дискриминационную способность. Random Forest был выбран рабочим champion по минимальной наблюдаемой бизнес-стоимости.

- Лучший уровень ROC-AUC среди нелинейных моделей: около 0,78.
- Калибровка снизила Brier Score Random Forest примерно с 0,174 до 0,136.
- Оптимальный бизнес-порог для champion-модели составил 0,262.
- Recall дефолтного класса составил около 91,6%.
- Ключевые факторы риска: глубина и длительность просрочек.
- Искусственный стресс-сценарий повысил средний PD с 0,41 до 0,56.

Оглавление

Краткое резюме	1
1 Данные и постановка задачи	3
1.1 Структура выборки	3
1.2 Предобработка и новые признаки	3
2 Методология	3
2.1 Модели	3
2.2 Метрики	4
2.2.1 ROC-AUC и Gini	4
2.2.2 KS	4
2.2.3 Brier score	4
2.2.4 Business cost	4
2.3 Статистическое сравнение	5
3 Результаты моделей	5
3.1 Сравнение качества	5
3.2 Bootstrap-сравнение	6
3.3 Калибровка	6
4 Бизнес-решение и champion-модель	6
5 Интерпретация и проверка признаков	8
5.1 SHAP-анализ	8
5.2 Новые признаки	10
6 Стресс-тест и мониторинг	11
7 Выводы и ограничения	11
7.1 Основные выводы	11
7.2 Ограничения	12
7.3 Дальнейшее развитие	12

1 Данные и постановка задачи

Цель проекта — построить модель оценки вероятности дефолта клиента по кредитной карте и сравнить несколько алгоритмов не только по качеству ранжирования, но и по точности вероятностных прогнозов, стоимости ошибок и устойчивости при изменении клиентского портфеля.

Целевая переменная принимает значение 1, если клиент допустил дефолт в следующем месяце, и 0 в противном случае.

1.1 Структура выборки

Для каждого клиента доступны сведения о кредитном лимите, демографических характеристиках, истории просрочек, суммах счетов и фактических платежах.

Таблица 1. Разделение выборки

Выборка	Число наблюдений	Назначение
Обучающая	18 000	Обучение моделей
Валидационная	6 000	Калибровка и выбор порога
Тестовая	6 000	Финальная оценка

Разбиение выполнялось со стратификацией по целевой переменной.

1.2 Предобработка и новые признаки

Пропуски заполнялись медианными значениями. Для логистической регрессии применялась стандартизация.

Были добавлены агрегированные признаки платёжной дисциплины и долговой нагрузки:

- avg_delay, max_delay, months_with_delay;
- avg_bill, max_bill, avg_payment, max_payment;
- utilization, payment_to_bill_ratio, bill_trend;
- delinquency_momentum, payment_coverage_ratio;
- weighted_payment_shortfall, recent_bill_growth.

Дополнительные признаки отражают гипотезы об ухудшении платёжного поведения, недостаточности платежей и росте долговой нагрузки.

2 Методология

2.1 Модели

В проекте сравнивались четыре алгоритма:

- Logistic Regression — интерпретируемый линейный baseline;
- Random Forest — bagging-модель на основе деревьев;
- HistGradientBoosting — градиентный бустинг на гистограммах;

- LightGBM — эффективный градиентный бустинг для табличных данных.

Для нелинейных моделей дополнительно выполнялась sigmoid-калибровка вероятностей на валидационной выборке.

2.2 Метрики

Для оценки моделей использовался набор взаимодополняющих метрик: ROC-AUC, Gini, KS, Average Precision, Brier Score, precision, recall и business cost. Использование нескольких метрик необходимо, поскольку каждая из них отражает отдельный аспект качества модели. Ассигасу не использовалась как основная метрика из-за дисбаланса классов, потому что модель может получить достаточно высокую ассигасу, предсказывая преимущественно класс 0.

2.2.1 ROC-AUC и Gini

ROC-AUC использовалась как основная метрика дискриминационной способности. Она показывает вероятность того, что случайно выбранному дефолтному клиенту модель присвоит более высокий риск, чем случайно выбранному недефолтному клиенту. Метрика не зависит от конкретного порога классификации и позволяет сравнивать способность моделей ранжировать клиентов.

Коэффициент Gini является линейным преобразованием ROC-AUC и часто используется в задачах кредитного риска:

$$\text{Gini} = 2 \cdot \text{ROC-AUC} - 1. \quad (1)$$

2.2.2 KS

KS-статистика показывает максимальное расстояние между накопленными распределениями model score для дефолтных и недефолтных клиентов. Чем выше значение KS, тем лучше модель разделяет два класса. Эта метрика была включена в анализ, поскольку она традиционно применяется при оценке скоринговых моделей.

2.2.3 Brier score

Brier Score использовался для оценки качества прогнозируемых вероятностей дефолта:

$$\text{Brier} = \frac{1}{n} \sum_{i=1}^n (p_i - y_i)^2. \quad (2)$$

где p_i — прогнозируемая вероятность дефолта, а y_i — фактическое значение целевой переменной. Чем меньше Brier Score, тем ближе прогнозируемые вероятности к фактическим исходам. Эта метрика дополняет ROC-AUC: модель может хорошо ранжировать клиентов, но при этом выдавать некорректные значения PD. Поэтому Brier Score использовался для оценки эффекта калибровки.

2.2.4 Business cost

Business cost определялась как

$$C = 100\,000 \cdot FN + 10\,000 \cdot FP. \quad (3)$$

False negative считался в десять раз дороже false positive.

2.3 Статистическое сравнение

Различия между моделями проверялись парным bootstrap на тестовой выборке. На каждой итерации формировалась новая выборка с возвращением, после чего рассчитывалась разница ROC-AUC и business cost.

3 Результаты моделей

3.1 Сравнение качества

Таблица 2. Результаты моделей на тестовой выборке

Модель	ROC-AUC	Gini	KS	Avg. Precision	Brier	Cost/applicant
Logistic Regression	0,7509	0,5019	0,3960	0,5034	0,1921	7 391,7
Random Forest	0,7808	0,5616	0,4274	0,5598	0,1738	6 931,7
HistGradientBoosting	0,7812	0,5625	0,4267	0,5595	0,1346	7 030,0
LightGBM	0,7801	0,5602	0,4315	0,5673	0,1745	7 150,0
Random Forest calibrated	0,7808	0,5616	0,4274	0,5598	0,1355	6 991,7
HistGradientBoosting calibrated	0,7812	0,5625	0,4267	0,5595	0,1346	6 943,3
LightGBM calibrated	0,7801	0,5602	0,4315	0,5673	0,1348	7 150,0

Нелинейные модели превзошли логистическую регрессию примерно на 0,03 ROC-AUC. Между Random Forest, HistGradientBoosting и LightGBM различия минимальны.




Рис. 1. ROC-кривые моделей

3.2 Bootstrap-сравнение

Таблица 3. Ключевые bootstrap-сравнения ROC-AUC

Сравнение	Разница AUC	95% CI
Logistic Regression – Random Forest	–0,0299	[–0,0378; –0,0220]
Logistic Regression – HistGradientBoosting	–0,0303	[–0,0384; –0,0225]
Logistic Regression – LightGBM	–0,0292	[–0,0379; –0,0204]
Random Forest – HistGradientBoosting	–0,0005	[–0,0034; 0,0025]
Random Forest – LightGBM	0,0007	[–0,0037; 0,0051]

Преимущество нелинейных моделей над логистической регрессией статистически устойчиво. Между нелинейными моделями значимых различий не обнаружено.

3.3 Калибровка




Рис. 2. Калибровочные кривые

Калибровка существенно улучшила Brier Score Random Forest и LightGBM, практически не изменив ROC-AUC.

4 Бизнес-решение и champion-модель

Порог выбирался на валидационной выборке путём минимизации ожидаемой стоимости ошибок. Для Random Forest оптимальный порог составил

$$t^* = 0,2624.$$




Рис. 3. Оптимизация бизнес-порога

Таблица 4. Матрица ошибок Random Forest

	Предсказан 0	Предсказан 1
Фактический 0	1 624	3 049
Фактический 1	111	12 16

Recall составил около 0,916, precision — около 0,285. Высокий recall достигнут ценой большого числа false positive.




Рис. 4. Матрица ошибок champion-модели

Random Forest был выбран рабочим champion по минимальной наблюдаемой стоимости. При этом его преимущество над boosting-моделями по cost статистически неустойчиво.

5 Интерпретация и проверка признаков

5.1 SHAP-анализ




Рис. 5. Глобальная SHAP-интерпретация

Ключевые факторы риска — глубина и длительность просрочек, высокий уровень использования лимита и недостаточность платежей.




Рис. 6. Средняя абсолютная SHAP-важность




Рис. 7. Локальное объяснение клиента с высоким PD

Следует учитывать корреляцию между max_delay, avg_delay, months_with_delay и PAY_0: эти признаки отражают сходные аспекты платёжной истории.

5.2 Новые признаки

Таблица 5. Эксперимент с расширенным набором признаков

Метрика	Baseline	Extended	Δ	Extended лучше
ROC-AUC	0,76233	0,76267	0,00034	66,7% фолдов
Average Precision	0,51177	0,51140	-0,00037	33,3% фолдов
Negative Brier	-0,19092	-0,19076	0,00016	100% фолдов

Новые признаки почти не улучшили ранжирование, но дали небольшое устойчивое улучшение качества вероятностных прогнозов.

6 Стресс-тест и мониторинг

В стрессовом сценарии были увеличены просрочки и задолженность, а последние платежи уменьшены.

Таблица 6. Стресс-метрики

Показатель	Значение
Средний PD на тесте	0,4104
Средний PD в стресс-сценарии	0,5567
Score PSI	0,8496
Доля выше порога на тесте	0,7108
Доля выше порога в стресс-сценарии	0,9233

Таблица 7. Наиболее изменившиеся признаки

Признак	PSI
delinquency_momentum	2,2377
PAY_3	1,3585
PAY_2	1,3317
avg_delay	1,2215
months_with_delay	1,2067
PAY_0	1,1752

Высокий PSI показывает сильное изменение риск-профиля портфеля, но не измеряет качество модели напрямую. Для оценки качества на новом периоде потребовались бы фактические значения целевой переменной.

7 Выводы и ограничения

7.1 Основные выводы

Нелинейные модели показали более высокий ROC-AUC, чем логистическая регрессия, а bootstrap-анализ подтвердил, что это преимущество статистически устойчиво. При этом различия между Random Forest, HistGradientBoosting и LightGBM оказались минимальными, поэтому по одной только ROC-AUC нельзя однозначно выбрать лучшую модель. Поэтому были добавлены другие метрики, на основе которых была выбрана champion-модель. В качестве нее был выбран Random Forest, поскольку при заданной стоимости ошибок он показал минимальную наблюдаемую business cost. Однако его преимущество над boosting-моделями не было статистически устойчивым, поэтому HistGradientBoosting и LightGBM также можно рассматривать как сильные альтернативы.

Калибровка заметно улучшила качество вероятностных прогнозов Random Forest и LightGBM, почти не изменив ROC-AUC. Это показывает, что хорошее ранжирование клиентов не всегда означает корректные значения PD. Оптимальный бизнес-порог оказался достаточно низким, поскольку стоимость пропущенного дефолта была задана значительно выше стоимости ошибочного отказа. Благодаря этому модель достигла высокого recall, но одновременно сформировала

большое количество FP.

SHAP-анализ показал, что основными факторами риска являются глубина и длительность просрочек, высокая загрузка кредитного лимита и недостаточность платежей. Новые поведенческие признаки почти не улучшили ROC-AUC, но дали небольшое улучшение Brier Score. Стресс-тест также показал, что модель ожидаемо повышает оценки риска при ухудшении характеристик портфеля.

7.2 Ограничения

- стоимости FN и FP заданы условно, в реальной задаче она должна рассчитываться с учетом суммы кредита, LGD, процентного дохода и стоимости ошибочного отказа надежному клиенту.
- стресс-сценарий искусственный, хотя для реального риск-моделирования предпочтительнее out-of-time validation. Стресс-сценарий был сформирован искусственно и использовался только для проверки чувствительности модели, а не для оценки ее фактического качества на новом периоде.
- использовано случайное, а не временное разбиение;
- часть признаков коррелирует;
- систематический nested CV не проводился.

7.3 Дальнейшее развитие

В дальнейшем можно провести out-of-time validation и проверить, насколько устойчиво качество моделей на данных более позднего периода. Также полезно сравнить текущие модели с классическим scorecard-подходом на основе WOE и IV.

Отдельным направлением может стать более реалистичная функция потерь с использованием PD, LGD и EAD, а также sensitivity analysis для разных соотношений стоимости false negative и false positive.

Дополнительно можно сравнить sigmoid- и isotonic-калибровку, провести более систематический подбор гиперпараметров и реализовать monitoring dashboard с PSI, Brier Score, ROC-AUC и показателями калибровки.